Как лучше моделировать сезонность на M4 Monthly

Исследовательский проект по временны́м рядам, TS HSE 2025–2026

Постановка задачи

В проекте проверяется гипотеза 6 из задания: какие признаки сезонности полезны для глобальной модели на месячных временных рядах и зависит ли эффект от силы сезонности и от горизонта прогнозирования.

Сравниваются несколько наборов признаков внутри одной глобальной модели CatBoostRegressor и обязательные бейзлайны: Naive, SeasonalNaive, auto.theta, auto.ets.

Распределение ролей

Работа выполнена индивидуально.

Данные

Источник данных: M4 Monthly из Monash Time Series Forecasting Repository. Для эксперимента использована подвыборка из 120 месячных рядов. Исходные временные метки брались из M4-info.csv, чтобы корректно строить календарные признаки.

Этот датасет выбран потому, что месячная сезонность напрямую подходит под постановку задачи, данные достаточно компактны, а сами ряды удобны для сравнения сезонных лагов, month-of-year и Fourier-признаков.

Протокол валидации

Использовался rolling backtest с двумя окнами. В каждом окне прогноз строился на горизонт 18 месяцев. Для оценки использовались две метрики: sMAPE и MASE.

Модели и признаки

Бейзлайны: Naive, SeasonalNaive, auto.theta, auto.ets.

Основная модель: CatBoostRegressor. В модель подавались series_id как категориальный признак, номер шага горизонта и лаговые признаки.

Сравнивались шесть вариантов признаков: только лаги; лаги + сезонные лаги; лаги + month-of-year; лаги + Fourier; лаги + сезонные лаги + month-of-year; лаги + сезонные лаги + Fourier.

Основные результаты

Средние результаты по всем рядам и обоим окнам приведены в таблице ниже.

Модель	sMAPE	MASE
auto theta	13.57	0.979
auto ets	15.12	0.977
naive	15.60	1.227
lags seasonal fourier	16.22	1.334

Модель	sMAPE	MASE
lags seasonal month	16.27	1.342
lags and seasonal	16.38	1.327
lags and month	16.69	1.352
lags	16.81	1.332
lags and fourier	17.11	1.384
seasonal naive	17.44	1.332

Лучшей моделью оказался auto.theta. Ни одна конфигурация CatBoost не обошла лучшие статистические бейзлайны. При этом внутри семейства CatBoost сезонные признаки оказались полезны: варианты с сезонными лагами и дополнительными seasonal-признаками лучше, чем модель только на обычных лагах.

Анализ по горизонту

На коротком горизонте лучший результат у auto.theta: на первом шаге sMAPE = 6.17. Далее идут auto.ets (6.68) и naive (7.18). Лучший CatBoost-вариант на первом шаге — lags + seasonal (9.65).

На 18-м шаге auto.theta тоже остается первым с sMAPE = 19.48. seasonal naive занимает второе место с 20.40. Лучший CatBoost-вариант на 18-м шаге — lags + seasonal + Fourier с 21.09.

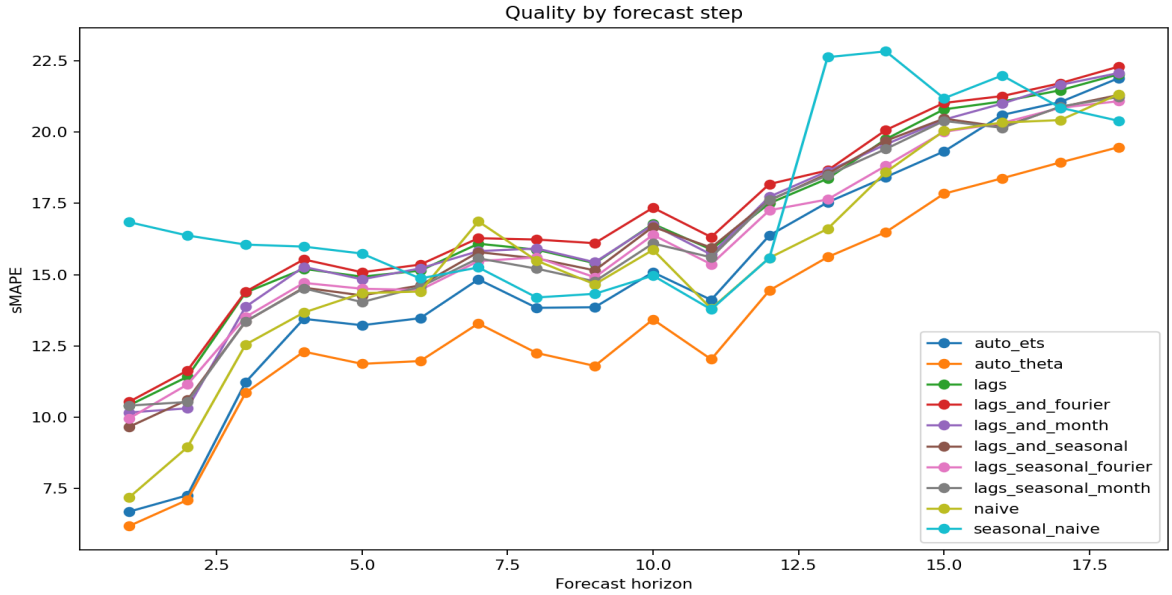

Рис. 1. sMAPE по шагам прогнозного горизонта.

Анализ по силе сезонности

Для каждого ряда была оценена сила сезонности через STL-декомпозицию, после чего ряды были разбиты на три группы: low, medium, high.

Для рядов со слабой сезонностью лучшие результаты показывают auto.theta, naive и auto.ets, а лучший CatBoost-вариант — lags + seasonal + Fourier.

Для рядов со средней сезонностью лучшим CatBoost-вариантом оказался lags + seasonal, но статистические модели все равно сильнее.

Для рядов с сильной сезонностью наиболее заметный эффект внутри CatBoost дают lags + seasonal + month и lags + seasonal + Fourier. Однако даже здесь лидируют seasonal naive и auto.theta.

Вывод

Гипотеза подтвердилась частично. Внутри глобальной ML-модели сезонные признаки действительно полезны, а их эффект зависит от силы сезонности и от шага горизонта. Особенно это заметно на рядах с выраженной сезонностью.

Однако на выбранной подвыборке M4 Monthly лучшие статистические бейзлайны, прежде всего auto.theta, оказались сильнее всех протестированных конфигураций CatBoost. Для месячных рядов разумно сначала проверять хорошие статистические модели, а уже потом переходить к более сложной глобальной ML-модели.